education

Инференс ML-моделей: От PyTorch до продакшена за 60 минут

ONNX → Triton Inference Server → vLLM

Петров Артем, разработчик
VK AI

Что разберём сегодня

01 — Экспорт модели: PyTorch → ONNX

02 — Triton Inference Server: батчинг, конфиг, мониторинг

03 — MLServer: KServe-совместимый альтернативный сервер

04 — vLLM: почему наивный HuggingFace в 10–20× медленнее

- Live demo в каждой секции

Секция 1
Экспорт модели (PyTorch → ONNX)

Экспорт модели (PyTorch → ONNX)

Почему формат так важен?

- .pt привязан к версии Python/PyTorch
- .onnx — открытый стандарт, работает на CPU
- torch.onnx.export() — одна строчка, на выходе

```python
# 1. Модель и пример входа
model = torchvision.models.resnet50(pretrained=True).eval()
dummy_input = torch.randn(1, 3, 224, 224)

# 2. Экспорт одной командой
torch.onnx.export(model, dummy_input, "model.onnx",
                  input_names=['input'], output_names=['output'],
                  dynamic_axes={'input': {0: 'batch_size'}}) # Важно для Triton!
```

Demo: resnet18_cifar10.ipynb → outputs/resnet18_cifar10.onnx

Секция 2
Triton Inference Server

Triton Inference Server: Архитектура

Зачем Triton?

- Dynamic Batching — объединяет запросы в пачки автоматически
- Метрики Prometheus из коробки
- Параллельные модели на одном GPU (ResNet + BERT одновременно)

model_repository/ — структура папок + config.pbtxt

```
model_repository/
└── resnet_onnx/
    ├── 1/
    │   └── model.onnx
    └── config.pbtxt
```

```
name: "resnet_onnx"
platform: "onnxruntime_onnx"
max_batch_size: 8
input { name: "input" data_type: TYPE_FP32 dims: [ 3, 224, 224 ] }
output { name: "output" data_type: TYPE_FP32 dims: [ 1000 ] }
```

Секция 3
MLServer



MLServer: Архитектура

Разработан Seldon для Kubernetes (KServe), отлично работает локально в Docker

V2 Inference Protocol — тот же стандарт, что у Triton → клиентский код взаимозаменяем

Подхватывает .onnx «из коробки» — не нужен config.pbtxt

```
{
    "name": "resnet18",
    "implementation": "mlserver_onnx.OnnxRuntime",
    "parameters": {
        "uri": "./resnet18_cifar10.onnx"
    }
}
```

```
docker run -it --rm \
    -p 8080:8080 \
    -v $(pwd):/mnt/models \
    seldonio/mlserver:latest \
    mlserver start /mnt/models/
```

Секция 4
LLM инференс (vLLM)

Специфика LLM инференса (vLLM)

Почему наивный HuggingFace медленный?

- Каждый запрос обрабатывается отдельно — GPU простаивает
- KV-cache не переиспользуется между запросами

Почему vLLM в 10–20× быстрее?

- PagedAttention — эффективное управление KV-cache
- Continuous batching — новые запросы встраиваются в текущий батч
- OpenAI-совместимый API — drop-in замена

```
curl http://localhost:8000/v1/completions -H "Content-Type: application/json" -d '{
    "model": "facebook/opt-125m", "prompt": "CIFAR-10 class names are",
"max_tokens": 20
}'
```

Команды и итоги

Команды, которые вы теперь знаете:

- make train → обучить ResNet-18 на CIFAR-10
- make export → экспорт в ONNX
- make triton / make mlserver / make vllm → запустить серверы

Файлы для самостоятельного изучения:

- Plan.md — полный тайминг воркшопа
- flow/section_3/client.ipynb — бенчмаркинг серверов
- flow/section_4/vllm_demo.ipynb — эксперименты с LLM

```
# MLServer
docker run -p 8080:8080 -v $(pwd):/mnt/models seldonio/mlserver:latest mlserver
start /mnt/models/

# Triton
docker run --gpus all -v $(pwd)/model_repository:/models -p 8000:8000 nvcr.io/nvidia/
tritonserver:24.01-py3 tritonserver --model-repository=/models

# vLLM
vllm serve facebook/opt-125m --port 8000
```



Спасибо за внимание!

Петров Артем, разработчик VK AI

education

education

VK Education для студентов: обучение и старт карьеры в IT

Открытые курсы VK Education

- **Гибкий график**: изучать материалы и выполнять задания можно в любое время;
- **Самостоятельное обучение**: все лекции от экспертов VK записаны на видео, а задания проверяются автоматически;
- **Отсутствие синхронизации**: на курсе нет дедлайнов и расписания — можно регулировать интенсивность обучения;
- **Отбор**: зачисление проходит после подачи заявки, нет требований по уровню подготовки;
  Сертификаты: после завершения курса учащиеся получают сертификат от VK Education

education

VK Education Projects

- База прикладных кейсов для диплома, курсовой или практики;
- Обратная связь от экспертов VK на лучшие решения;
- Подарки за лучшие решения;
- Сертификат, подтверждающий опыт работы с задачами бизнеса;

education



Стажировка VK

Для тех, кто хочет решать задачи, с которыми команды VK сталкиваются каждый день

- Оплачиваемая стажировка длительностью 6 месяцев
- Работа над реальными задачами под руководством персонального наставника
- Развитие профессиональных навыков в выбранном направлении

Узнать больше о стажировке

